

手写数字符兼垃圾分类

人工智能基础 —— 实践课(五)



- LeNet5 + MNIST被誉为深度学习领域的 "Hello world"。本实验主要介绍使用 MindSpore在MNIST手写数字数据集上开 发和训练一个LeNet5模型,并验证模型精 度。
- 根据学习的知识自主设计垃圾分类模型, 作业评分测试都将基于垃圾分类进行。
- 附加题: 手机端部署垃圾分类模型并测试



MNIST数据集



MNIST 数据集来自美国国家标准与技术研究所,训练集 (training set) 由来自 250 个不同人手写的数字构成,其中 50% 是高中学生,50% 来自人口普查局 (the Census Bureau) 的工作人员.测试集(test set) 也是同样比例的手写数字数据.

- Training set images: train-images-idx3-ubyte.gz (9.9 MB, 解压后 47 MB, 包含 60,000 个样本)
- Training set labels: train-labels-idx1-ubyte.gz (29 KB, 解压后 60 KB, 包含 60,000 个标签)
- Test set images: t10k-images-idx3-ubyte.gz (1.6 MB, 解压后 7.8 MB, 包含 10,000 个样本)
- Test set labels: t10k-labels-idx1-ubyte.gz (5KB, 解压后 10 KB, 包含 10,000 个标签)

数据预处理:

- 1. mini-batch vs. full-batch: 设定批训练大小batch-size
- 2. Resize: 统一缩放图片到统一标准大小
- 3. Rescale: 数据归一化
- 4. HWC2CHW: 将图像矩阵的高宽通道三个维度进行调整对换
- 5. Others: 旋转, 翻转, 裁剪, 高斯噪声, 灰度转换, 亮度, 饱和度...

mindspore.dataset()
mindspore.dataset.transforms.c_transforms()
mindspore.dataset.vision.c_transforms()

数据预处理

```
import matplotlib.pyplot as plt
                                                                                 Number: 1
                                                                                                        Number: 3
ds = create dataset('MNIST', training=False)
data = ds.create dict iterator().get next()
images = data['image'].asnumpy()
                                      (32, 1, 32, 32)
labels = data['label'].asnumpy()
                                      (32,)
                                                                                 Number: 5
                                                                                                        Number: 7
for i in range(1, 5):
                                                                             0
    plt.subplot(2, 2, i)
    plt.imshow(images[i][0])
                                                                                                    10
    plt.title('Number: %s' % labels[i])
                                                                                                    20
    plt.xticks([])
plt.show()
```

数据预处理

mindspore.dataset.MnistDataset(dataset_dir, usage=None, num_samples=None, num_parallel_workers=None, shuffle=None, sampler=None, num_shards=None, shard_id=None, cache=None):

- dataset_dir (str) 包含数据集的根目录的路径.
- shuffle (bool, optional) 是否打乱数据集, 默认为不打乱数据集顺序.

mindspore.dataset.MnistDataset.map(input_columns, operations):

- input_columns=['key']: 对["image"]或["label"]执行数据变换
- operations: 数据变换,如CV.Resize(resize),CV.Rescale(rescale, shift),CV.HWC2CHW(),C.TypeCast(ms.int32)


其中:

import mindspore.dataset.transforms.c_transforms as C import mindspore.dataset.vision.c_transforms as CV

mindspore.dataset.MnistDataset.shuffle(buffer_size=buffer_size).batch(batch_size, drop_remainder=True)

- buffer_size:将被加入缓冲器的元素的最大数
- batch size: 一批输入网络训练的样本数量
- drop_remainder:当epoch剩余样本数不足一个batch的时候,直接丢弃还是 保留直接作为一个batch


LeNet5



mindspore.nn.Conv2d(in_channels, out_channels, kernel_size, stride = 1, pad_mode = 'same', padding = 0, dilation = 1, group = 1, has_bias = False, weight_init = 'normal', bias_init = 'zeros', data_format = 'NCHW')

Output Height:
$$\left[1 + \frac{H_{in} + 2 \times \text{padding} - \text{ks_h} - (\text{ks_h} - 1) \times (\text{dilation-1})}{\text{stride}}\right]$$


Output Weight:
$$\left[1 + \frac{H_{in} + 2 \times \text{padding} - \text{ks}_{\underline{\text{w}}} - (\text{ks}_{\underline{\text{w}}} - 1) \times (\text{dilation-1})}{\text{stride}}\right]$$



mindspore.nn.Conv2d(in_channels, out_channels, kernel_size, stride = 1, pad_mode = 'same', padding = 0, dilation = 1, group = 1, has_bias = False, weight_init = 'normal', bias_init = 'zeros', data_format = 'NCHW')


Output Height:
$$\left[1 + \frac{H_{in} + 2 \times \text{padding} - \text{ks_h} - (\text{ks_h} - 1) \times (\text{dilation-1})}{\text{stride}}\right]$$

Output Weight:
$$\left[1 + \frac{H_{in} + 2 \times \text{padding} - \text{ks}_{\underline{\text{w}}} - (\text{ks}_{\underline{\text{w}}} - 1) \times (\text{dilation-1})}{\text{stride}}\right]$$



MindSpore官方文档: https://www.mindspore.cn/doc/api python/zh-CN/master/index.html

activation



MindSpore官方文档: https://www.mindspore.cn/doc/api python/zh-CN/master/index.html

optimal

```
def train(data_dir, lr=0.01, momentum=0.9, num_epochs=3, ckpt_name="lenet"):
    ds_train = create_dataset(data_dir)
    ds_eval = create_dataset(data_dir, training=False)
    steps_per_epoch = ds_train.get_dataset_size()

net = LeNet5()
    loss = nn.loss.SoftmaxCrossEntropyWithLogits(sparse=True, reduction='mean')
    opt = nn.Momentum(net.trainable_params(), lr, momentum)

    ckpt_cfg = CheckpointConfig(save_checkpoint_steps=steps_per_epoch, keep_checkpoint_max=5)
    ckpt_cb = ModelCheckpoint(prefix=ckpt_name, directory=CKPT_DIR, config=ckpt_cfg)
    loss_cb = LossMonitor(steps_per_epoch)

model = Model(net, loss, opt, metrics={'acc', 'loss'})
    model.train(num_epochs, ds_train, callbacks=[ckpt_cb, loss_cb], dataset_sink_mode=False)
    metrics = model.eval(ds_eval, dataset_sink_mode=False)
    print('Metrics:', metrics)

train(DATA_PATH)
```

mindspore.nn.loss.SoftmaxCrossEntropyWithLogits

For each instance N_i , the loss is given as:

$$\ell(x_i, t_i) = -\log\Biggl(rac{\exp(x_{t_i})}{\sum_j \exp(x_j)}\Biggr) = -x_{t_i} + \log\Biggl(\sum_j \exp(x_j)\Biggr),$$

where x_i is a 1D score Tensor, t_i is a scalar.

optimal

```
def train(data_dir, lr=0.01, momentum=0.9, num_epochs=3, ckpt_name="lenet"):
    ds_train = create_dataset(data_dir)
    ds_eval = create_dataset(data_dir, training=False)
    steps_per_epoch = ds_train.get_dataset_size()

net = LeNet5()
    loss = nn.loss.SoftmaxCrossEntropyWithLogits(sparse=True, reduction='mean')
    opt = nn.Momentum(net.trainable_params(), lr, momentum)

ckpt_cfg = CheckpointConfig(save_checkpoint_steps=steps_per_epoch, keep_checkpoint_max=5)
    ckpt_cb = ModelCheckpoint(prefix=ckpt_name, directory=CKPT_DIR, config=ckpt_cfg)
    loss_cb = LossMonitor(steps_per_epoch)

model = Model(net, loss, opt, metrics={'acc', 'loss'})
    model.train(num_epochs, ds_train, callbacks=[ckpt_cb, loss_cb], dataset_sink_mode=False)
    metrics = model.eval(ds_eval, dataset_sink_mode=False)
    print('Metrics:', metrics)
```

• mindspore.nn.Momentum

$$v_t = v_{t-1} * u + gradients$$

If use_nesterov is True:

$$p_t = p_{t-1} - (grad * lr + v_t * u * lr)$$

If use_nesterov is Flase:

$$p_t = p_{t-1} - lr * v_t$$

模型参数保存

```
def train(data_dir, lr=0.01, momentum=0.9, num_epochs=3, ckpt_name="lenet"):
    ds_train = create_dataset(data_dir)
    ds_eval = create_dataset(data_dir, training=False)
    steps_per_epoch = ds_train.get_dataset_size()

net = LeNet5()
    loss = nn.loss.SoftmaxCrossEntropyWithLogits(sparse=True, reduction='mean')
    opt = nn.Momentum(net.trainable_params(), lr, momentum)

ckpt_cfg = CheckpointConfig(save_checkpoint_steps=steps_per_epoch, keep_checkpoint_max=5)
    ckpt_cb = ModelCheckpoint(prefix=ckpt_name, directory=CKPT_DIR, config=ckpt_cfg)
    loss_cb = LossMonitor(steps_per_epoch)

model = Model(net, loss, opt, metrics={'acc', 'loss'})
    model.train(num_epochs, ds_train, callbacks=[ckpt_cb, loss_cb], dataset_sink_mode=False)
    metrics = model.eval(ds_eval, dataset_sink_mode=False)
    print('Metrics:', metrics)

train(DATA_PATH)
```

ModelCheckpoint可以保存模型参数,以便进行再训练或推理。 LossMonitor 可以在日志中输出loss,方便用户查看,同时它还会监控训练过程中的loss 值变化情况,当loss值为Nan或Inf时终止训练。

加载Checkpoint进行验证


```
CKPT = os.path.join(CKPT_DIR, 'lenet-3_1875.ckpt')

def eval(data_dir):
    ds_eval = create_dataset(data_dir, training=False)
    net = LeNet5()
    loss = nn.loss.SoftmaxCrossEntropyWithLogits(sparse=True, reduction='mean')
    load_checkpoint(CKPT, net=net)
    model = Model(net, loss, metrics={'acc', 'loss'})
    metric = model.eval(ds_eval, dataset_sink_mode=False)
    print(metric)

eval(DATA_PATH)
```

```
def infer(data_dir):
    ds = create dataset(data dir, training=False).create dict iterator(output numpy=True)
    data = ds.get next()
    images = data['image']
   labels = data['label']
   net = LeNet5()
   load checkpoint(CKPT, net=net)
   model = Model(net)
   output = model.predict(Tensor(data['image']))
    preds = np.argmax(output.asnumpy(), axis=1)
   for i in range(1, 5):
       plt.subplot(2, 2, i)
        plt.imshow(np.squeeze(images[i]))
        color = 'blue' if preds[i] == labels[i] else 'red'
       plt.title("prediction: {}, truth: {}".format(preds[i], labels[i]), color=color)
        plt.xticks([])
    plt.show()
infer('MNIST')
```


全连接神经网络的局限性



如果只有两个隐藏层,每层256个节点,则MNIST数据集所需要的参数是(28*28*256+256*256+256*10)个w,再加上(256+256+10)个b。

- 如果输入图像大小宽高为1000像素,仅一层全连接就需要1000*1000*256个参数,约等于2亿个w。
- 而卷积神经网络使用了参数共享的方式,换一个角度来解决问题,不仅在准确率上大大提升,也把参数降下来。

卷积核




这些噪点,属于高频信号

高频信号,就好像平地耸立的山峰




平滑这座山峰的办法之一就是,把山峰刨掉一些土,填到山峰周围去。用数学的话来说,就是把山峰周围的高度平均一下。即把高频信号与周围的数值平均一下就可以平滑图像。



$$g = \begin{bmatrix} 1/9 & 1/9 & 1/9 \\ 1/9 & 1/9 & 1/9 \\ 1/9 & 1/9 & 1/9 \end{bmatrix}$$

卷积核



a,b的下标相加都为1,1

$$f = egin{bmatrix} a_{0,0} & a_{0,1} & a_{0,2} \ a_{1,0} & a_{1,1} & a_{1,2} \ a_{2,0} & a_{2,1} & a_{2,2} \end{bmatrix} \quad g = egin{bmatrix} b_{-1,1} & b_{-1,0} & b_{-1,1} \ b_{0,-1} & b_{0,0} & b_{0,1} \ b_{1,-1} & b_{1,0} & b_{1,1} \end{bmatrix}$$

$$\begin{aligned} c_{1,1} &= a_{0,0}b_{1,1} + a_{0,1}b_{1,0} + a_{0,2}b_{1,-1} + a_{1,0}b_{0,1} \\ &+ a_{1,1}b_{0,0} + a_{1,2}b_{0,-1} \ + a_{2,0}b_{-1,1} \\ &+ a_{2,1}b_{-1,0} + a_{2,2}b_{-1,-1} \end{aligned}$$


卷积公式形式:

$$(f * g)(1, 1) = \sum_{k=0}^{2} \sum_{h=0}^{2} f(h, k)g(1-h, 1-k)$$

加权求和-卷积滤波

离散卷积本质就是一种加权求和.

卷积神经网络中的卷积操作本质上就是利用一个共享参数的卷积核(filter),通过逐点计算中心像素点以及相邻像素点的加权和来构成feature map实现空间特征的提取。



MobileNetV2 垃圾分类

本实验以MobileNetV2+垃圾分类数据集为例,主要介绍如在使用 MindSpore 在 CPU/GPU 平台上进行 Fine-Tune。

垃圾分类信息:

{ '干垃圾': ['贝壳', '打火机', '旧镜子', '扫把', '陶瓷碗', '牙刷', '一次性筷子', '脏污衣服'], '可回收物': ['报纸', '玻璃制品', '篮球', '塑料瓶', '硬纸板', '玻璃瓶', '金属制品', '帽子', '易拉罐', '纸张'],

'湿垃圾': ['菜叶', '橙皮', '蛋壳', '香蕉皮'],

'有害垃圾':['电池', '药片胶囊', '荧光灯', '油漆桶']}

['贝壳', '打火机', '旧镜子', '扫把', '陶瓷碗', '牙刷', '一次性筷子', '脏污衣服', '报纸', '玻璃制品', '篮球', '塑料瓶', '硬纸板', '玻璃瓶', '金属制品', '帽子', '易拉罐', '纸张', '菜叶', '橙皮', '蛋壳', '香蕉皮'.

'电池', '药片胶囊', '荧光灯', '油漆桶']

['Seashell', 'Lighter','Old Mirror', 'Broom','Ceramic Bowl', 'Toothbrush','Disposable Chopsticks','Dirty Cloth', 'Newspaper', 'Glassware', 'Basketball', 'Plastic Bottle', 'Cardboard','Glass Bottle', 'Metalware', 'Hats', 'Cans', 'Paper', 'Vegetable Leaf','Orange Peel', 'Eggshell','Banana Peel', 'Battery', 'Tablet capsules','Fluorescent lamp', 'Paint bucket']

附加题 - 手机端部署模型

本实验不要求完成附加题.

附加题可以同学们课后自己实验学习. 不计入成绩.

最终测试准确率达到85%以上即可获得满分.

准确率达到80%以上+完整的实验报告及中间结果记录也可获得满分.

准确率以5%为一档向下逐档减分.

Note:

- (1) 垃圾分类作业通过调参模型即可获得85%以上的准确率(需要同学们对各项参数的理解有较高的理解,调参最高准确率目前记录为93%).
- (2) 可以采用pytorch或tensorflow框架编程. 但需要保证接口与mindspore模型中的函数接口一致.
- (3) 本题是开放题,如果调参较难取得满意结果,也可以修改模型架构,加载预训练模型之后重新训练整个模型,或者用不同的训练策略,或者数据增强方式都可以用来提升模型的鲁棒性能.对于模型的Loss的设定也可以增加一些弱监督信息,或者人类知识先验信息.
- (4) 高阶: 鲁棒性模型 —— GAN, 对比学习, 数据增强模型, VAE, Attention机制等等.